

Projet 5: Pipeline ETL Intelligent pour Analyse des Ventes avec Agent IA d'Insights

Contexte métier

Une entreprise e-commerce centralise ses données de vente issues de plusieurs canaux (site web, points de vente physiques, réseaux sociaux) dans un entrepôt de données, et s'appuie sur un agent IA pour transformer ces données en recommandations exploitables — sans intervention humaine pour la première lecture des résultats.

Contexte technique

Le projet combine un pipeline ETL classique (extraction, nettoyage, transformation, chargement, orchestration, monitoring) avec une couche agentique : un agent LLM consomme les données transformées et produit automatiquement des analyses en langage naturel (résumés de tendances, détection d'anomalies, recommandations priorisées).

Étapes clés

1. Extraire les données de vente depuis plusieurs sources (API REST, fichiers CSV, base relationnelle SQLite/Postgres).
2. Nettoyer et transformer les données (doublons, formats, enrichissement de catégories, calcul de métriques métier : marge, panier moyen, taux de croissance).
3. Charger les données transformées dans un entrepôt local (DuckDB ou PostgreSQL).
4. Orchestrer le pipeline avec Prefect (planification, dépendances, retries).
5. Mettre en place le monitoring technique (logs structurés, alertes sur échecs/anomalies de volume).
6. Agent IA d'insights : à chaque exécution réussie, un agent (Claude via API) interroge les données agrégées et génère un rapport en langage naturel — top produits, périodes de pic, tendances émergentes, anomalies détectées, recommandations actionnables.
7. Exposer les résultats (pipeline + rapports IA) via un dashboard simple (Streamlit) consultable par un utilisateur métier non technique.

Technologies

- Extraction : Python (pandas, requests, SQLAlchemy)
- Transformation : Pandas, dbt-core (sur DuckDB)
- Chargement : DuckDB ou PostgreSQL local
- Orchestration : Prefect
- Monitoring : logs structurés (Python logging) + tableau de bord Streamlit
- Couche agentique : API Anthropic (Claude), prompt structuré pour génération de rapports JSON/texte
- Visualisation : Streamlit + Plotly

Livrable final

Repo GitHub avec README bilingue FR/EN, architecture documentée (diagramme), code modulaire, rapport IA d'exemple, dashboard accessible localement ou via Streamlit Cloud.